

# 前言

“机器学习的数学基础”是在2026年秋季学期首次面向大二金融工程/金融学专业学生开设的课程，课程原有讲义基本由AI生成。虽然课程框架由AI生成，有诸多不合理的地方，我仍然选择保证原有讲义的课程逻辑，但将原讲义中忽略、简写和无解释的内容解释丰富，包括但不限于：重要定理证明，理论思路推导，缺失背景补充，缩略内容展开。由于是出于本人自用的目的，所以其中有很大一部分不是本课程考察之内的内容，请读者批判性阅读。

本课程每周两课时，就讲义内容而言，是依照本课课时为线索编写，只有与金融相关的例子。由于笔者知识水平受限且本讲义实则是笔者的个人笔记，难免有错误或不严谨的地方，希望读者指正。

其次，本课程属于针对商学院学生开设的“机器学习先导课程”。所以相对基础，要求不高。

本讲义若无特殊说明，即默认以下前提：

1.集合 $C$ 表示凸集

2. $\mathbf{w}$ 表示向量，更多时候表示权重向量。

本讲义涉及以下内容，理论上不属于考察范围，可以跳过：

1.凸性理论

2.机器学习专业内容

3. $n$ 元 $n$ 维（本课只考察3维及以下）

希望这份讲义对各位有所参考，祝大家学得愉快。

# 機器學習的數學基礎

## 第一课时

公式1.0  $\left| \mathbf{a}^T \mathbf{b} \right| \leq \|\mathbf{a}\| \|\mathbf{b}\|$  (柯西不等式)

概念1.1 梯度 (gradient)

特指损失函数 $L(\theta)$ 对模型参数 $\theta$ 的一阶偏导向量，记作 $g(\theta) = \nabla L(\theta)$ 。此时每个分量 $\frac{\partial L}{\partial \theta_i}$ 直接代表调整该参数对损失变化的敏感度。梯度为零是驻点，是开集内部局部极值的必要条件，沿负梯度方向迭代更新参数 $\eta$ 。

公式1.2  $\begin{pmatrix} x_{i+1} \\ y_{i+1} \end{pmatrix}_{new} \approx \begin{pmatrix} x_i \\ y_i \end{pmatrix} - \eta \nabla f(x_i, y_i)$

解释：这个公式的功能是利用负梯度下降最快来更新参数，目的是逼近某些参数的最优解。

推导：由Taylor展开在点 $x_i$ 附近对 $f$ 做线性近似 $f(x_i + \Delta x) \approx f(x_i) + \nabla f(x_i)^T \Delta x$ ，由于我们忽略了Taylor展开中 $\Delta x^2$ 及以上的高阶项，因此公式1.1仅仅在步长 $\eta$ 足够小的时候成立，所以我们用 $\approx$ 而不是 $=$ 。为了到达逐步减小损失函数的目的，我们需要让函数值下降，即增量为负

$\nabla f(x_i)^T \Delta x < 0$ ，利用柯西不等式（1.1）求解这一项的最值：

$\left| \nabla f(x_i)^T \Delta x \right| \leq \|\nabla f(x_i)\| \|\Delta x\| \leftrightarrow -\|\nabla f\| \|\Delta x\| \leq \nabla f^T \Delta x \leq \|\nabla f\| \|\Delta x\|$  也就是向量 $\Delta x$ 和 $\nabla f(x_i)$ 反

向共线时等号成立，那么可以写成 $\Delta x = -\eta \nabla f(x_i)$  ( $\eta > 0$ )，回代 $x_{i+1} = x_i + \Delta x$ 得到公式1.2:

$$x_{i+1} = x_i - \eta \nabla f(x_i)$$

补充： $\eta$ 为“学习率”也叫“步长”，这是一个不大于Lipschitz常数分之2的参数（即 $\eta < \frac{2}{L}$ ，前提是梯度连续），Lipschitz常数一般等于损失曲面最大曲率（也就是Hessian矩阵最大特征值上界）

例1.0 给出某金融资产已实现的两期收益 $x_1 = 1\%$ ， $x_2 = 3\%$ ，求未来一期的预期收益率 $\mu$ ，已知 $\mu$ 满足损失函数： $L(\mu) = (\mu - x_1)^2 + (\mu - x_2)^2$

解： $L(\mu)' = 4\mu - 8$ ，令 $L(x)' = 0$ ，得 $\mu = 2$

续例1.0 若给出二元形式:  $L(x, y) = (x - x_1)^2 + (y - y_1)^2$ , 那么同样令:

$$\nabla L(x, y) = \begin{pmatrix} 2(x - x_1) \\ 2(y - y_1) \end{pmatrix} = \vec{0} \leftrightarrow \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x_1 \\ y_1 \end{pmatrix}$$

下面给出一些有关梯度的命题:

命题1.1 (梯度与等高线正交性) 设函数  $f$  可微, 在满足  $\nabla f \neq \mathbf{0}$  的点处:

1. 梯度向量  $\nabla f$  与过该点的等高线  $f(x, y) = c$  的切方向相互正交
2.  $\nabla f$  指向函数值增大的一侧
3. 沿等高线切向做无穷小位移, 函数的一阶变化量为0

命题1.2 (n元函数梯度的同构性) 设  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  连续可微, 则梯度

$$\nabla f = \left( \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)^T$$

依旧由各个自变量对应的偏导数按列组装得到; 几何意义保持不变:  $\nabla f$  为  $\mathbb{R}^n$  内该点的最陡上升方向。二元、三元的计算与几何结论可以直接推广到高维空间。

命题1.3 (方向导数与梯度的关系) 设  $\hat{u}$  为  $\mathbb{R}^n$  中的单位向量,  $D_{\hat{u}}f$  表示  $f$  沿方向  $\hat{u}$  的方向导数, 则  $D_{\hat{u}}f = \nabla f \cdot \hat{u}$  设  $\nabla f \neq \mathbf{0}$ , 记  $\|\nabla f\|$  为梯度向量的2-范数:

1. 当  $\hat{u}$  取梯度的单位化方向  $\frac{\nabla f}{\|\nabla f\|}$  时, 方向导数取得最大值  $\|\nabla f\|$ , 对应最陡上升方向
2. 当  $\hat{u}$  取  $-\frac{\nabla f}{\|\nabla f\|}$  时, 方向导数取得最小值  $-\|\nabla f\|$ , 对应最陡下降方向
3. 当  $\hat{u}$  与  $\nabla f$  正交时,  $D_{\hat{u}}f = 0$ , 沿该方向移动函数一阶不变

命题1.4 (开集内部极值的必要条件) 若可微函数  $f$  在定义域开集内部的点取得局部极大值或局部极小值, 则该点处梯度为零向量:  $\nabla f = \mathbf{0}$

---


## 机器学习中的应用 (p1.0)

损失函数  $L(\theta)$  是参数空间 (Parameter Space) 中的曲面, 训练模型就是在找损失函数的极小点, 也就是  $\nabla L = \vec{0}$ 。若无法解出, 利用批量GD沿负梯度方向更新参数  $\theta$ 。后续会详细介绍两种

常用的办法，方法一是解析解法，算出线性回归的最小二乘： $w = (X^T X)^{-1} X^T y$ ，方法二是利用梯度下降（Gradient Descent），迭代数值解法：选一个初始参数点，反复执行公式1.2.

**参数空间：**损失函数的定义域，模型所有可调参数的全部可能取值构成的集合。

梯度下降的几何直观示例：



## 第一课时选修内容：

### \*1.1 神经网络（本课程是基础课程，这部分内容属于ML课程）

面对线性回归模型无法解决的“非线性”模式，人们最开始选择依靠人工构造非线性特征，但是这种做法严重依赖人的先验知识，而神经网络可以让模型自动生成非线性特征。

神经网络的本质是线性变换和非线性算子的多层交替。也就是对于每一层进行如下的处理：先利用矩阵进行拉伸或者旋转的变换，再利用ReLU激活函数进行“弯折”，多层叠加之后可以拟合非常复杂的曲面。

**定义ReLU激活函数：** $ReLU(t) = \max\{0, t\}$ ，解释一下就是，正分量不变，负分量被“弯折”成0。

整个“隐藏层”的处理过程是这样的：第一层处理后“弯折后”的折线，又在第二层处理时进行矩阵运算，有了新的“位置”，之后重复每一层的过程。

### \*1.2 训练循环

我们不考虑其中具体细节，大概逻辑分为五个步骤。

步骤一：前向传播。把数据送入模型，得到模型预测结果。

步骤二：计算损失 $L(\theta)$ 。对比预测值和真实值，算出损失函数，衡量当前模型好坏。

步骤三：反向传播。这是关键一步，要输出损失函数对所有参数的梯度 $\nabla L$ 。

步骤四：更新参数。利用公式1.2更新参数。

步骤五：重复迭代。

### \*1.3 偏导存在不等于可微，可微要求偏导连续。

---

## 第二课时

### 定义2.1 向量

$\mathbb{R}^n$ 中的向量是n个实数排成的有序组，默认写成列向量（row vector）

$\vec{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$  两个向量相等的充要条件是对应的分量全部相等。

公式2.1 二维分量可以表示仓位  $\vec{u} = \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}$

$u_1$ : 沿第一轴（股票）的分量

$u_2$ : 沿第二轴（债券）的分量

思考题：基金怎么用向量表示，FOF又是怎么用这些向量组合成的？

---

### 机器学习中的应用（p2.0）

一个样本的特征常写成 $\mathbb{R}^d$ 里的一个向量  $X_T = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$ ，其中每个分量可以表示：年龄，性别，收入

等等。


信用评级模型把客户属性排成向量，每个分量是可观测的一个维度。

公式2.2 向量加法数乘公式（略）

命题2.3 数乘的几何意义 $c\vec{u}$  高中数学讲过，不再赘述，这里仅提醒在金融语境下的应用： $c = 2$ 意味着加倍仓位； $c = -0.5$ 则意味着卖出一半的仓位。

---

三维仓位加法：仍是分量相加、首尾相接



### 机器学习中的应用（p2.1）

对于多个模型输出的预测向量进行向量加法和数乘运算就是集成学习中加权平均多个模型输出的过程。

**集成学习：综合多个模型输出结果**

**预测向量：**多个模型的输出作为分量排成一个列向量

在量化交易中，对于仓位的数乘和加法对应着多个子策略信号加权求和再放缩杠杆。举个例子：某一天收盘之后，你接收到了很多个子策略的“建议”，子策略A说买入0.2手，子策略B说卖出0.4手，子策略C说……，我们把他们加起来，得到了净信号，再用老板说加的多少杠杆（实际操作中会受到风险管理委员会，数学模型和法律的约束）乘上去，这就是明天的交易决策。

**子策略信号 (SUB-STRATEGY SIGNAL)：**某投资组合由若干个相互独立的量化交易子策略构成，第 $i$ 个子策略在 $t$ 时刻输出的净持仓指令记作实值随机变量  $S_i(t)$ ， $S_i(t)$ 被称为子策略信号。

**杠杆 (LEVERAGE)：**通常代指资金乘数系数，记作  $c \in \mathbb{R}^+$ 。在仓位决策中，它对已完成求和或加权的中性信号执行数乘，以调整实际风险暴露水平。这一操作严格对应数乘运算。

## 概念2.4 线性组合

对于给定的  $\vec{u}_1, \dots, \vec{u}_k \in \mathbb{R}^n$  与实数  $c_1, \dots, c_k$ ，称

$$c_1 \vec{u}_1 + \dots + c_k \vec{u}_k$$

为这些向量的一个线性组合 (Linear Combination) 系数  $c_i$  称为权重或配方。

此外，若满足  $c_i \geq 0$  且  $\sum c_i = 1$  的线性组合，我们定义为凸组合，对于凸组合，我们有一个非常重要的性质定理。但真正见到这个性质定理之前，我们必须理解一些非常复杂的概念。

## 引理2.5 凸集 (Convex Set)

若在一个集合  $C$  中任取两个点所组成的凸组合仍在这个集合  $C$  中，那么这个集合  $C$  被称为凸集。比如全空间，凸多面体，闭欧氏球都是凸集，但圆环，互不相交凸集的并集，以及整数格点都不是凸集。

**凸组合的集合不一定是凸集，但是所有凸组合的集合一定是凸集，某些取 $K$ 个凸组合的集合不是凸集。**

首先定义2.5.1 凸包 (Convex Hull)：包含所有  $\vec{u}_i$  的最小凸集，记为  $\text{conv}(\{\vec{u}_i\})$

那么有这样一条定理：所有凸组合的集合恰好等于这些点的凸包。我们用数学语言描述，看起来是这样的：

$$\text{公式2.5.2 } \text{conv}(S) = \left\{ \sum_{i=1}^n c_i \vec{u}_i \mid \vec{u}_i \in S, c_i \geq 0, \sum_{i=1}^n c_i = 1, n \in \mathbb{N} \right\}$$

这就是著名的凸包定理 (Convex Hull Theorem)，因为投资组合本身就是凸组合，所以我们目前讨论的概念为后续我们关注的重要问题——凸优化，做了重要铺垫。因为若损失函数是凸函数，

根据凸函数的定义，则其“定义域”（可行域）必为凸集，那么任意局部极小值一定是全局极小值。这是凸优化问题的理论基础。

我们回到原讲义的内容上来，原讲义对于这个性质的描述是“……凸组合，几何上落在顶点连成的线段或多边形内……”我们接下来会描述这个定理的几何状态，但是必须要引入更多的概念。

首先需要解读的是“顶点”，这里指的是凸包的角点（Corner Points）

定义2.5.3 极端点（Extreme Point）

这里叫角点，指的是在凸集中无法被写成其他任意两个点的凸组合的点。

这里很形象的描述是：在二维平面，这些焦点就是多边形的角；在三维空间，这些焦点就是多面体的棱角。

所以我们根据凸组合的定义可知，只要取这些角点做凸组合，那么最后生成的结果一定会填满这个凸集。当然，这个凸集可以是线段，多边形，多面体，甚至n维多面体，而这些所有的凸组合显而易见会落在这个“边界”之内。

接下来，这个讲义写了一个错误的反例“「线性组合必须权重非负且和为1」——那是把理财约束写进了定义”这里提及“理财约束”又让人摸不着头脑，在这里给出注解：“理财约束”本质上是标准 $(n-1)$ 维概率单纯形 $\Delta^{n-1}$ 的定义，也就是凸组合的系数落在概率单纯形 $\Delta^{n-1}$ 上，下面给出其定义：

$$\text{公式2.5.4 } \Delta^{n-1} = \{c \in \mathbb{R}^n \mid c_i \geq 0, \sum_{i=1}^n c_i = 1\}$$

我们只需要知道，后续关于投资组合的理论很多是以这个为背景的即可，不做过多深究。

概念2.6 张成span

一组向量的span=它们全部线性组合的集合，若该集合等于整个空间，则称其为生成集。

$$\text{span}\{\vec{u}_1, \dots, \vec{u}_k\} = \{c_1\vec{u}_1 + \dots + c_k\vec{u}_k \mid c_i \in \mathbb{R}\}$$

下边给出一些关于张成的命题：

命题2.6.2 平面上两向量张成直线或整个平面，同理，三个向量可能张成直线，平面或整个 $\mathbb{R}^3$

此二阶行列式是否等于零来判断“线还是面”

---

## 机器学习中的应用 (p2.2)

特征空间里某个张成（可解释部分），是线性分类器能表示的得分方向集合。换句话说，这个张成是选取权重向量的限制。

**线性分类器：**简单来说就是一条直线或者一个平面，公式是  $f(x) = w^T \vec{x} + b$ ，它会给每个样本算一个得分，正负决定分类。

**得分方向：**描述“权重向量” $\vec{w}$ ，它决定了分类看中哪些特征。

**可解释部分：**指预测值中能被特征线性解释的那一部分。

有了这些基本概念，我们可以试图解释为什么 $\vec{w}$ 会受到这个张成的限制。首先我们假设有一个有  $n$  个样本  $d$  个维度的数据集，其特征矩阵是  $X \in \mathbb{R}^{N \times d}$ ，根据公式，权重向量可以表示为  $\vec{w} = X^T \alpha$ ，也就是说，这个向量一定是由训练样本得出的线性组合，也就是不超过张成的空间。

**注意区分此处的样本特征矩阵  $X \in \mathbb{R}^{N \times d}$  与线性分类器公式中的样本列向量  $\vec{x}$  完全不一样！**

---

## 第三课时

### 概念3.1 内积

我们在交易中需要判断两只股票的多期收益的“共变关系”，量化这两只股票走势的“相似度”，常常使用内积这一工具，第九课时我们介绍 P A C 时仍会提到。

这里原讲义有这样一句话“……禁止用  $(t, P_t)$  价格曲线做内积……”刚接触金融数据分析的人可能会把几只股票的历史价格数据，也就是价格序列，通过内积的手段判断其“共变关系”，这样出错在哪呢？我们分别给出股票 A 和股票 B 的三期收益：

$$P(A) = (10, 12, 17)$$

$$P(B) = (17, 12, 10)$$

$$\langle P_A, P_B \rangle = 10 \times 17 + 12 \times 12 + 17 \times 10 = 484$$

如此一看两只股票同向变化极强，但是实际上若拿出股票 A，B 的简单收益向量计算：

$$r_A = (0.2, 0.417)$$

$$r_B = (-0.2941, -0.1667)$$

$$\langle r_A, r_B \rangle = 0.2 \times (-0.2941) + 0.417 \times (-0.1667) = -0.12832$$

得出正确结论，实际上两者反向变动

所以说向量内积处理的是某一个向量的多个“维”对应做运算的，而不是某一个标量。

定义3.1.2 欧氏内积

对于  $\vec{u}, \vec{v} \in \mathbb{R}^n$ ，定义

$$\vec{u} \cdot \vec{v} = u_1 v_1 + \dots + u_n v_n = \sum_{i=1}^n u_i v_i$$

定义3.1.3 欧几里得范数 (Euclidean Norm)

有人把范数 (norm) 这一概念近似于高中的“模长”，这实际上是不全面的，因为范数通俗地说是一个满足范数公理，并且输入是向量，输出是非负实数的函数，或者说给向量量“长度”。欧式范数的结果就是高中生所熟知的“模长”，如果在一个空间上定义了内积，那么可以诱导出欧式范数：

$$\|x\|_2 = \sqrt{x^T x}$$

但是不能诱导出在  $\mathbb{R}^n$  上的  $L^1$  范数，也就是熟知的“曼哈顿距离”，也不能诱导出  $\mathbb{R}^n$  上的  $L^\infty$  范数，也就是“最大范数”，原因是他们不满足平行四边形恒等式：

$$\|\mathbf{x} + \mathbf{y}\|^2 + \|\mathbf{x} - \mathbf{y}\|^2 = 2\|\mathbf{x}\|^2 + 2\|\mathbf{y}\|^2$$

对于给定的  $\vec{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ ，其欧几里得范数定义为该向量各分量平方和的算术平方根：

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

范数公理：

1. 正定性：  $\|x\| \geq 0, \|x\| = 0 \leftrightarrow x = 0$

2. 齐次性：  $\|\alpha x\| = |\alpha| \|x\|$

3. 三角不等式：  $\|x + y\| \leq \|x\| + \|y\|$

---

## 机器学习中的应用 (p3.0)

原讲义这里介绍了线性模型的决策评分函数定义为  $f(x) = w^T X = \vec{w} \cdot \vec{x}$  (权重向量与特征向量的内积) 也就是“打分”，这在第二课时的“机器学习中的应用”板块对于“线性分类器”的描述一致，不过多赘述。

这也能用于对于不同消费者消费行为模式的归类上。

### 概念3.2 欧氏距离 (Euclidean Distance)

欧氏距离就是两个向量差的欧式范数：

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2$$

举一个在交易中的例子：

将某一周的股收益与债收益组成二维向量，比较两周的状态差异：

$$\mathbf{r}_2 = (0.02, 0.01)^T, \mathbf{r}_3 = (0.05, -0.02)^T$$

$$\|\mathbf{r}_2 - \mathbf{r}_3\| = \sqrt{0.0018}$$

这个向量差的范数指示当前市场结构差异性。其测度值越大，表明市场内部的相对强弱结构变化越剧烈，触发再平衡或对冲调整的紧迫性越高。在统计操作中，常常先中心化再使用。这是由于原始收益向量中包含大盘的整体走势，如果不中心化处理，欧式距离会被这一走势主导，掩盖资产间真实的相对强弱变化。所以这是后续计算协方差矩阵与 PCA 的统计前提。

---

## 第四课时 (机器学习中的应用p4.0)

### 概念 4.1 kNN (k-Nearest Neighbors)

一种基于距离度量的非参数监督学习方法。“非参数”意味着它不假设数据的分布形式，也不进行显式训练，而是“Instance- based Learning”在训练阶段只存储历史数据。这一特质决定了它非常擅长处理非线性数据，同时兼具极强的解释性。它的预测机制是对于给定的新样本，计算它和历史所有样本的欧氏距离，选出范数测度值最小的k个邻居，在这k个邻居之间进行“分类”或者“回归”从而决定新样本的属性。

### 概念 4.2 $\ell_2$ 正则 ( $\ell_2$ regularization)

定义 4.2.1  $\ell_2$ 正则化是指在原损失函数上加一个正则项，从而得到正则化目标函数的操作。

这种工具创造出来的目的，是解决权重向量长度过长的问题，长度过长通常会引发机器学习中的四种问题：过拟合，对输入扰动过于敏感，优化困难，系数解释失效。下面是核心机制的解释。

给定原始损失函数为 $L(\mathbf{w})$ ，权重向量 $\vec{w} \in \mathbf{R}^d$ ，那么正则化后目标函数通常写为：

$$J(\mathbf{w}) = L(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2。 \quad (\text{公式 4.2.2})$$

其核心机制是用正则项 $\lambda \|\mathbf{w}\|_2^2 = \lambda \sum_{j=1}^n \mathbf{w}_j^2$ “惩罚”权重向量过大，正则化后的函数再参与到梯度下降

算法中计算，是这样的：

1. 先对正则化后的函数求导：  $\nabla J(\mathbf{w}) = \nabla L(\mathbf{w}) + 2\lambda \mathbf{w}$
2. 再代入梯度下降算法中：  $\begin{pmatrix} x_{i+1} \\ y_{i+1} \end{pmatrix}_{new} \approx \begin{pmatrix} x_i \\ y_i \end{pmatrix} - \eta \nabla J(x_i, y_i)$  (公式1.2)
3. 或者我们把原先展开的列向量替换成 $\vec{w}$ ，可能形式上看更连贯，得到：

$$\mathbf{w}_{new} = \mathbf{w} - \eta \nabla J(\mathbf{w}) = \mathbf{w} - \eta \nabla L(\mathbf{w}) - 2\eta \lambda \mathbf{w}$$

这里我们不难发现，如果 $\vec{w}$ 的长度越长，那么纠正 $\vec{w}$ 的力度就越大。此外， $\ell_2$ 正则是一种“软约束”，因为它没有硬性规定权重的范围，而是给增大权重赋予了“代价”。

若原始损失函数 $L(\mathbf{w})$ 凸且连续下有界， $\lambda > 0$ ，则 $\ell_2$ 正则化后的函数 $J(\mathbf{w}) = L(\mathbf{w}) + \lambda \|\mathbf{w}\|^2$ 一定强凸\* (strong convexity)，如果函数满足强凸条件，那么存在唯一全局极小点。

\*下面补充凸函数、严格凸和强凸的定义。

定义4.2.3 凸函数 (convex function)

若集合 $C$ 是一个凸集，且对于 $\forall x, y \in C, \forall \lambda \in [0,1]$ ，函数 $f$ 都满足

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

则称 $f$ 为凸函数。

我们从几何直观上看，凸函数 $f$ 图像上任意两点的连线，都在图像上方。同时，如果我们把两个点推广到任意有限个点，凸函数必定满足定义，得到著名的Jensen不等式：

$$(公式 4.2.3.1) \quad f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n \lambda_i f(x_i), \text{ 当满足 } \lambda_i \geq 0, \sum_{i=1}^n \lambda_i = 1 \text{ 时成立}$$

在概率论中由于期望就是凸组合，所以下面式子也成立：

$$f(\mathbf{E}[\mathbf{X}]) \leq \mathbf{E}[f(\mathbf{X})] \quad (公式 4.2.3.2)$$

这条不等式可以很好地解释信息熵的凸性，以及对数效用下的最优配置问题。由于凸性理论内容庞杂，剩余有关凸性理论的基础内容在后边的讲义中会单列。

定义 4.2.4 严格凸(strict convexity)

$\forall x, y \in C$  且  $x \neq y$ ,  $\forall \lambda \in (0,1)$ , 函数  $f$  都满足

$$f(\lambda x + (1 - \lambda)y) < \lambda f(x) + (1 - \lambda)f(y)$$

则称  $f$  严格凸。

定义 4.2.5 强凸 ( $\mu$ -强凸) (strong convexity)

若对于  $\forall x, y \in C$ ,  $\forall \lambda \in [0,1]$ , 函数  $f$  都满足

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) |x - y|^2$$

则称  $f$  为  $\mu$ -强凸

概念 4.3 余弦相似度 (Cosine Similarity)

从数学角度定义，是这样的： $\cos \theta = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\| \|\vec{v}\|}$  (定义 4.3.1)，我们高中就学过。但是这里

侧重的是余弦的功能性：余弦这个量恰好把长度这种表示“规模”除掉了，所以从功能的角度看，余弦可以近似描述“相不相似”，当然这只是对两个或  $n$  个向量“像不像”的粗略估计。

在投资中，两种产品的收益序列余弦相似度高，说明其走势形状“像”。

机器学习中的应用 (p4.1)

推荐系统向用户个性化推荐时，会用到余弦近似描述其“相似性”。

推荐系统(recommender system)的例子很常见，美团，拼多多，京东……等等平台都千方百计地想让你评价购买的商品，这是因为它们可以把用户对商品的评价排列成一个向量，比如对于

五部电影，用户评价向量可能是(1,3,5,5,4)，那么这个向量刻画了用户的“偏好画像”，平台把数以千计的向量用余弦相似度刻画后，归类描述“群体”。

#### 概念4.4 TF-IDF向量

机器学习中处理文本时常用一种叫做TF-IDF向量的技术，首先为了让机器开始理解人类自然语言，首先会把全部文档收集在一起，形成的集合叫做语料库（corpus），对语料库中所有文档分词后，经过去重，制定出词汇表（vocabulary）。

假设一个词汇表有一万个词，那么我们会把接下来的所有文章，无论是20词还是2000000词的，都表示为一个一万维的向量，每一个维度对应词汇表中的一个词，这个维度的数值就是这个对应词在这篇文章的权重，也就是TF-IDF值。那么最后这个一万维的向量就是TF-IDF向量，代表着这篇文章的“内容特征”。TF-IDF向量往往非常高维，非常稀疏，绝大多数都是0，极少数有非0数值。

有了两个例子的铺垫，我们简单介绍一下TF-IDF向量的概念，其全称叫Term Frequency-Inverse Document Frequency(TF-IDF)，中文直译是“词频—逆文档频率”技术。TF值，是统计每个词在此文档中出现的频率后得出的结果；IDF值则指示这个词在整个语料库中的稀有程度。最后的TF-IDF值等于TF与IDF的乘积。

如果给定文档d，那么文档d的TF-IDF向量形似：

$$v_d = [TFIDF(t_1, d), \dots, TFIDF(t_n, d)]$$

其中，给定语料库中文档总数是N，语料库中包含词 $t_i$ 的文档数为  $DF(t_i)$

$$IDF(t_i) = \ln \frac{N + 1}{DF(t_i) + 1} + 1 \quad (\text{加性平滑处理后})$$

$$TF(t_i, d) = \frac{\text{The frequency of } t_i \text{ in } d}{TWC(d)}$$

$$TFIDF = TF(t_i, d) \times IDF(t_i)$$

#### 概念4.5 正交

定义：  $\langle \vec{x}, \vec{y} \rangle = 0 \Leftrightarrow$  正交

##### 命题4.5.1 勾股定理

若满足 $\langle \vec{u}, \vec{v} \rangle = 0$ ，则

$$\|\vec{u} + \vec{v}\|^2 = \|\vec{u}\|^2 + \|\vec{v}\|^2$$

命题 4.5.2 三角不等式（范数公理第三条）

对于 $\forall \vec{u}, \vec{v} \in \mathbb{R}^n$ ，有

$$\|\vec{u} + \vec{v}\| \leq \|\vec{u}\| + \|\vec{v}\|$$

当且仅当两向量同向时，等号成立

概念4.6 正交补

定义：与所有 $\mathbf{S}$ 中的元素正交的向量集合，被称为 $\mathbf{S}$ 的正交补，即：

$$\mathbf{S}^\perp = \{ \vec{w} \mid \forall \vec{s} \in \mathbf{S}, \vec{w} \cdot \vec{s} = 0 \}$$

举一个例子，在二维平面中，如果 $\mathbf{S}$ 表示x轴： $\mathbf{S} = \text{span}\{(1,0)^T\}$ ，

$$\text{那么 } \mathbf{S}^\perp = \text{span}\{(0,1)^T\}$$

概念4.7 Gram-Schmidt扶正

这是在欧氏空间内一种将线性无关向量系构造成标准正交基的构造性方法。

现在假设有一个线性无关系向量 $(v_1, \dots, v_j)$

其核心机制是：将第一个向量 $v_1$ 看作第一个正交方向 $u_1$ ，用 $v_2$ 减去 $v_2$ 与 $v_1$ 同向的分量（ $v_2$ 在 $v_1$ 方向上的投影）得到 $u_2$ ，用 $v_3$ 减去和 $u_1$ 与 $u_2$ 之和，以此类推。规范表达如下：

$$u_j = v_j - \sum_{i=1}^{j-1} \text{proj}_{u_i} v_j = v_j - \sum_{i=1}^{j-1} \frac{\langle v_j, u_i \rangle}{\langle u_i, u_i \rangle} u_i \quad (\text{公式4.7.1})$$

这样形成的向量组满足对于 $\forall i < j$ ， $\langle u_j, u_i \rangle = 0$

而且正交化后仍满足张成空间不变：

$$\text{span}\{v_1, \dots, v_j\} = \text{span}\{u_1, \dots, u_j\}$$

在机器学习中，标准正交基让 $\text{Col}(X)$ 内部互不干扰，回归系数更稳定，简单来说，标准的正交基可以让每个方向的特征不杂糅在一起，系数估计也不再相互纠缠。如果经过正交处理，那么 $X^T X$

不是一个对角矩阵，每一个方向都是都是 $x_j^T y$ 的线性组合（关于最小二乘，详见《凸性理论基础 | 第一章》）。

$\text{Col}(X)$ :  $\text{Col}(X) = \text{span}\{X\beta_j, j = 1, \dots, n\}$ , 表示矩阵  $X$  的列空间。

## 第五课时

**我们终于能在这里把前四课时中所有复杂的概念联系起来了。**对于给定线性预测函数：

$f(x) = w^T x + b$ ,  $x$  表示特征向量,  $w^T$  表示权重向量的转置, 转置原因是：默认  $w$  是一个一个列向量, 需要转置为行向量才能与特征向量运算。 $b$  表示偏置, 一般都会经过中心化处理, 则  $b = 0^*$ 。

由于测量误差, 存在未观测变量或事件本身具有内在随机性等种种原因, 导致出现噪声  $\varepsilon$ , 那么原线性预测函数变化为观测函数  $y = w^T x + b + \varepsilon$ 。

将损失函数定义为平方误差\*：

$$L(\theta) = \sum_{i=1}^n (y_i - w_i^T x_i - b_i)^2$$

把所有特征向量  $x_i$  按行堆叠, 形成特征矩阵  $X$ :

$$X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} \in \mathbf{R}^{n \times d}$$

一般来说, 定义回归系数向量  $\beta = \begin{pmatrix} w \\ b \end{pmatrix} = \theta$ , 为了方便, 我们一般对特征矩阵  $X$  增广处理:

$$\text{令 } \tilde{X} = [X, 1]$$

$$\tilde{X}\beta = [X, 1] \begin{pmatrix} w \\ b \end{pmatrix} = Xw + b = \mathcal{H} = \text{span}\{1, x_1, \dots, x_d\} \quad (\text{公式 5.1})$$

( $\mathcal{H}$  表示所有的  $f(x)$  的集合)

习惯上把特征矩阵  $X$  与设计矩阵  $\tilde{X}$  “混为一谈”, 统一记做“ $X$ ”, 因为形式更加一般化和简洁。

所以：

$$y - X\beta = \begin{pmatrix} y_1 - \beta_1^T x_1 \\ \vdots \\ y_n - \beta_n^T x_n \end{pmatrix}$$

那么，按照（公式 5.1）的逻辑：

$$L(\beta) = \|y - X\beta\|^2 \quad (\text{公式 5.2})$$

所以，求解线性模型的损失函数最小值，本质上是一个最小二乘问题：

$$\min_{\beta} \|y - X\beta\|^2$$

结果简单：  $\hat{\beta} = (X^T X)^{-1} X^T y$ （推导过程见《凸性理论基础 | 第一章》）

最后解方程得到的是一个估计量，而不是一个确定量。原因是噪声的存在。

\*p5.2 对于损失函数选取平方误差函数的解释

假设噪声项  $\varepsilon$  服从均值为0，方差为  $\sigma^2$  的高斯分布（见《凸性理论基础》1.1）

$$\varepsilon \sim N(0, \sigma^2 I_n)$$

在  $x$  给定， $w$  是参数，所以  $w^T x$  是常数。计算条件均值：

$$\mathbf{E}[y | x] = w^T x + \mathbf{E}[\varepsilon | x] = w^T x$$

由高斯性保持可得：

$$y | X, \beta, \sigma^2 \sim N(X\beta, \sigma^2 I_n)$$

似然为：

$$p(y | X, \beta, \sigma^2) = \sqrt{\frac{1}{(2\pi\sigma^2)^n}} \exp\left(-\frac{1}{2\sigma^2}(y - X\beta)^2\right)$$

取负对数似然：  $\ln L = \frac{n}{2} \ln 2\pi\sigma^2 + \frac{1}{2\sigma^2} \|y - X\beta\|^2$

去除无关常数项和正因子，得到该问题等价于：

$$\min_{\beta} \|y - X\beta\|^2$$

\*关于众多概念的补充说明

标准线性模型： $y = X\beta + \varepsilon$  (4.7.2)，其中  $\beta$  表示回归系数向量（模型参数），所有的  $\beta_j$  表示参数空间， $X$  是特征矩阵， $X\beta \in \text{Col}(X)$  表示预测空间， $y \in \mathbf{R}^n$  表示观测空间（样本空间）， $\varepsilon$  表示不可观测的噪声。损失函数  $L(\theta)$  实际上是在参数空间里定义了一个曲面，这个曲面的曲率是  $2X^T X$ ，估计量的协方差是  $\text{Cov}(\hat{\beta}) = \sigma^2(X^T X)^{-1}$ ，回归系数向量  $\beta$  是损失函数  $L(\theta)$  的极小点。

机器学习的目的是从数据中估计模型参数  $\theta$ ，令预测的损失最小化。在目前课时内接触的线性模型中，这个  $\theta$  就是回归系数向量  $\beta$ 。

\*Bishop 在《PRML》中并不是如此介绍的，而是先定义了一个基函数  $\Phi(x)$ ，简单来说把  $b$  “分摊”到了  $w$  和基函数中。